Zavod za elektroniku, mikroelektroniku, računalne i inteligentne sustave

Duboko učenje

završni ispit

1. (10b) Zadani su niz operacija unaprijednog prolaza i nedovršeni niz operacija unatražnog prolaza: Unaprijedni prolaz: Unatražni prolaz:

$$h = Wx + b, \quad (W \in \mathbb{R}^{m \times n})$$

$$h' = \text{ReLU}(h)$$

$$s = \mathbf{w}^{\mathsf{T}} \mathbf{h}'$$

$$L = -\ln(\sigma(s))[y = 1] - \ln(1 - \sigma(s))[y = 0],$$

$$\frac{\partial L}{\partial \mathbf{w}} = \frac{\partial L}{\partial s} \cdot \dots, \quad \frac{\partial L}{\partial \mathbf{h}'} = \dots$$

$$\vdots$$

$$\frac{\partial L}{\partial (W_{[i::]})^{\mathsf{T}}} = \dots, \quad \frac{\partial L}{\partial \mathbf{b}} = \frac{\partial L}{\partial \mathbf{h}}.$$

Zadaci:

- a) (1b) Koliko operacija skalarnog zbrajanja i množenja je potrebno za izračunavanje h uz najjednostavniju implementaciju?
- b) (2b) Napišite izraz za izračunavanje elementa $h_{[i]}$ preko definicije matričnog množenja i izvedite derivacije $\frac{\partial h_{[i]}}{\partial x_{[j]}}$, $\frac{\partial h_{[i]}}{\partial W_{[k,l]}}$ i $\frac{\partial h_{[i]}}{\partial b_{[j]}}$.
- c) (1b) Kojih su dimenzija tenzori w, $\frac{\partial h'}{\partial h}$ i $\frac{\partial L}{\partial h'}$ i koliko je njihovih elemenata je uvijek 0?
- d) (4b) Dovršite jednadžbe unatražnog prolaza tako da se dobiju derivacije gubitka (jakobijani) po međurezultatima i parametrima bez redundantnih operacija.
- e) (2b) Nacrtajte računske grafove unaprijednog i unatražnog prolaza tako da čvorovi predstavljaju ulazne varijable (npr. x, w) i međurezultate s operacijama (npr. (h, +), $(h', \operatorname{ReLU})$), a bridovi izravne zavisnosti po uzoru na sliku dolje. Elementarnim operacijama smatrajte matrično množenje, zbrajanje vektora, ReLU i cijelu operaciju računanja gubitka $(s, y) \mapsto L$.

Rješenje:

- a) (1b) (m-1)n+m=mn zbrajanja (priznati i mn+m), mn množenja
- b) (2b)

$$m{h}_{[i]} = \sum_i m{W}_{[i,j]} m{x}_{[j]} + m{b}_{[j]}, \quad rac{\partial m{h}_{[i]}}{\partial m{x}_{[j]}} = m{W}_{[i,j]}, \quad rac{\partial m{h}_{[i]}}{\partial m{W}_{[k,l]}} = \llbracket k = i
rbracket m{x}_{[l]}, \quad rac{\partial m{h}_{[i]}}{\partial m{b}_{[j]}} = \llbracket i = j
rbracket$$

- c) (1b) $\dim(\boldsymbol{w}) = m$ (priznati i (m,1)), $\dim\left(\frac{\partial h'}{\partial h}\right) = (m,m)$ i $\dim\left(\frac{\partial L}{\partial h'}\right) = (1,m)$
- d) (4b):

$$\frac{\partial L}{\partial s} = \sigma(s) - [y = 1]$$

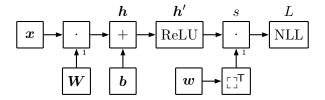
$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial s} \frac{\partial s}{\partial h'} = \frac{\partial L}{\partial s} w^{\mathsf{T}}, \quad \frac{\partial L}{\partial h'} = \frac{\partial L}{\partial s} \frac{\partial s}{\partial w} = \frac{\partial L}{\partial s} h'^{\mathsf{T}}$$

$$\frac{\partial L}{\partial h} = \frac{\partial L}{\partial h'} \frac{\partial h'}{\partial h} = \frac{\partial L}{\partial h'} \operatorname{diag}(\operatorname{sgn}(h'))$$

$$\frac{\partial L}{\partial (\mathbf{W}_{[i,:]})^{\mathsf{T}}} = \frac{\partial L}{\partial h} \frac{\partial h}{\partial (\mathbf{W}_{[i,:]})^{\mathsf{T}}} = \frac{\partial L}{\partial h_{[i]}} \frac{\partial h_{[i]}}{\partial (\mathbf{W}_{[i,:]})^{\mathsf{T}}} = \frac{\partial L}{\partial h_{[i]}} x^{\mathsf{T}}, \quad \frac{\partial L}{\partial b} = \frac{\partial L}{\partial h} \frac{\partial h}{\partial b} = \frac{\partial L}{\partial h}.$$

Izvod (0 bodova, traži se u 3. zadatku):

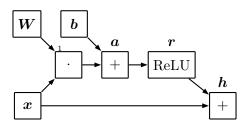
$$L = \ln(\exp(s) - 1) - s[y = 1] \implies \frac{\partial L}{\partial s} = \frac{\exp(s)}{\exp(s) - 1} - [y = 1] = \sigma(s) - [y = 1]$$



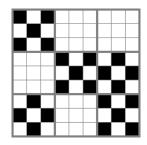
TODO unatražni graf

- f) Poboljšanje zadatka: Reći da x nije mini-grupa, nego samo 1 primjer. Tražiti $\frac{\partial h'_{[i]}}{\partial h_{[j]}}$. "skalarno zbrajanje i množenje" može biti dvoznačno množenje skalara i skalarni produkt. Umjesto crtanja cijelog unatražnog grafa tražiti samo dodjelivanje jakobijana strelicama? Naći bolji način da se kaže da pišu jednadžbe bez redundancije (prepisivanja već napisanog).)
- 2. (10b) Nadopunite layers.py iz druge laboratorijske vježbe razredom koji opisuje modul na slici. Podsjetite se da sučelje Layer implementira sljedeće tri metode:
 - forward(self, inputs) vraća izlaz sloja
 - backward_inputs(self, grads) vraća gradijent po ulazu
 - backward_params(self, grads) vraća listu parova (parametar, gradijent po parametru)

Implementirajte prikazani modul u Pytorchu ili Tensorflowu.



3. (10b) Vaš prijatelj X Æ A-12 je profesionalni e-sports igrač u igri "Kružić i križić" i treba pomoć. X Æ A-12 posjeduje bazu odigranih igara i želi izbrojati koliko puta je pobjedio igrajući kao X (križić). Završno stanje svake igre zabilježeno je binarnom slikom veličine 9x9 piksela. Slike u bazi su strukturirane na način da su znakovi uvijek pravilni i ucrtani unutar odgovarajućih zamišljenih ćelija veličine 3x3 piksela. Na slici desno vidimo primjer znaka X u ćeliji gore lijevo, a znaka O u ćeliji dolje lijevo. Crni pikseli na slici imaju vrijednost jednaku 1, a bijeli 0. Sivi rubovi zapravo ne postoje, dodani su samo zbog preglednosti. Vaši zadaci su sljedeći:



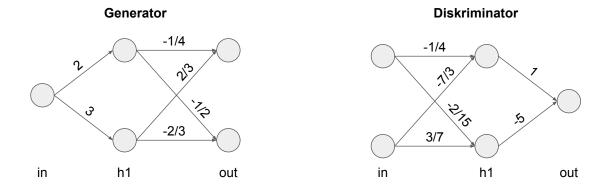
- (a) (5b) razmatramo model zadan nizom slojeva: konvolucijski sloj, potpuno povezani sloj, sloj globalnog sažimanja maksimumom, sigmoida; odrediti vrijednosti svih hiperparametara i parametara takve da model ispravno klasificira ulazne slike u dva razreda (pobjeda X i ostalo);
- (b) (2b) provesti jedan unaprijedni prolaz za ulaz zadan slikom i demonstrirati da Vaš model radi ispravno.
- (c) (3b) izvesti gradijente gubitka binarne unakrsne entropije po klasifikacijskim mjerama (ulazima sigmoide).
- 4. (3b) Razmatramo dvoslojni LSTM s dimenzijom skrivenog stanja 500 te dimenzijom ulaznih reprezentacija prvog sloja 300. Odredite ukupan broj parametara navedene mreže.
- 5. (7b) Razmatramo običnu povratnu neuronsku mrežu s prijenosnom funkcijom **logističke sigmoide** na povratnoj vezi i bez izlaznog sloja. Neka su poznati parametri povratne mreže:

$$m{W}_{\mathsf{hh}} = \left[egin{array}{cc} 2\ln(\sqrt{2}) & 0 \ 0 & 2\ln(\sqrt{2}) \end{array}
ight] \qquad m{W}_{\mathsf{xh}} = \left[egin{array}{cc} 1 & 1 \ -1 & 0 \end{array}
ight] \qquad m{b}_{\mathsf{h}} = \left[egin{array}{cc} 0 \ 0 \end{array}
ight]$$

Odredite skriveno stanje $h^{(2)}$ nakon dva vremenska koraka ako je poznato da je početno skriveno stanje inicijalizirano na nul vektor, a ulazi u prva dva vremenska koraka su:

$$m{x}^{(1)} = \left[egin{array}{c} 2 \ln(\sqrt{2}) \ 2 \ln(\sqrt{2}) \end{array}
ight] \qquad m{x}^{(2)} = \left[egin{array}{c} 0 \ 1.5 \ln(\sqrt{2}) \end{array}
ight]$$

6. (10b) Zadan je osnovni GAN sljedeće arhitekture i težina.



Za generator su aktivacijske funkcije na svim slojevima ReLU, a u diskriminatoru su LeakyReLU s negativnim nagibom vrijednosti 0.2, osim izlaznog neurona diskriminatora, čija je aktivacija sigmoidalna funkcija. U mreži su svi pomaci nepromijenjivi i jednaki 0.

Pri treniranju se prvo korigiraju težine diskriminatora, a tek onda generatora.

- (a) Opišite na koji način se trenira navedeni GAN.
- (b) Navedite optimizacijski cilj treniranja.
- (c) Za navedeni GAN izračunajte novo stanje težina sloja h_1 generatora i h_1 diskriminatora nakon jednog koraka učenja, uz stopu učenja od 1, s minigrupom veličine 3, ulaznim uzorcima šuma u generator vrijednosti $-0.5,\ 0.5,\ 0$ i skupom podataka od tri elementa: $[0,0],\ [1,1]$ i [2,2].